

**Implementasi YOLOv8 dalam Pengklasifikasian Sampah**  
**(Studi Kasus: Robot KRTMI ASTRO\_24)**

**Mata Kuliah: Kecerdasan Buatan**

**Kelas : RK-A2**

**Kelompok : 1**



Anggota Kelompok:

1. Zinadine Zidan Alsyahana (163221014)
2. Jeffrey Nobel Martin (163221040)
3. Stevanus Saut Hamonangan Gultom (163221050)
4. Affa Ndaru Rabbany Wijaya (163221061)

**Program Studi Teknik Robotika dan Kecerdasan Buatan**

**Fakultas Teknologi Maju dan Multidisiplin**

**Universitas Airlangga**

**2024**

## DAFTAR ISI

<b>BAB I PENDAHULUAN.....</b>	<b>1</b>
1.1 Latar Belakang .....	1
1.2 Rumusan Masalah.....	3
1.3 Tujuan .....	3
1.4 Manfaat .....	3
1.5 Batasan Masalah .....	4
<b>BAB II TINJAUAN PUSTAKA .....</b>	<b>5</b>
2.1 Sistem Pengklasifikasian Sampah Otomatis.....	5
2.2 <i>Computer Vision</i> .....	6
2.3 <i>Convolutional Neural Networks (CNN)</i> .....	7
2.4 YOLOv8.....	9
<b>BAB III PEMBAHASAN DAN ANALISA DATA .....</b>	<b>11</b>
3.1 Pengambilan Data .....	11
3.2 Pra-Pemrosesan Data.....	15
3.3 Pembuatan Model YOLOv8.....	15
3.4 Evaluasi Model .....	17
<b>BAB IV KESIMPULAN DAN SARAN .....</b>	<b>19</b>
4.1 Kesimpulan .....	19
4.2 Saran.....	19
<b>DAFTAR PUSTAKA.....</b>	<b>21</b>

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang

Dengan terus meningkatnya populasi penduduk di perkotaan, jenis dan jumlah sampah domestik menjadi semakin banyak dan kompleks, serta dampak lingkungan dari kehidupan perkotaan juga semakin meningkat. Penanganan sampah domestik yang tidak tepat dapat menyebabkan pencemaran lingkungan yang serius, seperti pencemaran air, udara, dan tanah, yang pada gilirannya berdampak buruk pada kesehatan manusia dan ekosistem. Selain itu, penanganan yang buruk juga menyebabkan pemborosan sumber daya yang signifikan, karena banyak bahan yang sebenarnya dapat didaur ulang atau digunakan kembali malah berakhir di tempat pembuangan akhir (Zhang *et al.*, 2022).

Menurut laporan *World Bank* (Kaza *et al.*, 2018), sebanyak 3,40 miliar ton sampah akan dihasilkan pada tahun 2050. Peningkatan besar dalam produksi sampah padat ini dapat memiliki dampak yang sangat besar terhadap lingkungan alam jika tidak dikelola dengan baik. Seiring dengan meningkatnya perhatian terhadap konsep “Zero Waste,” pembentukan sistem manajemen sampah yang berkelanjutan menjadi bagian yang sangat penting dari strategi pembangunan masa depan. Dari perspektif penilaian siklus hidup, pemilahan sampah di sumbernya dan pemulihan material adalah metode manajemen sampah yang paling ramah lingkungan dan dapat memberikan manfaat lingkungan lebih besar dibandingkan pembakaran atau pembuangan di tempat pembuangan akhir (Coelho dan Lange, 2018). Oleh karena itu, terdapat kebutuhan mendesak untuk identifikasi dan daur ulang sampah secara cerdas yang efisien dan akurat.

Berbagai teknologi dan metode yang digunakan untuk memilah sampah saat ini telah tersedia, seperti pemilahan secara manual, pemilahan berbasis arus *eddy*, pemilahan logam, pemilahan berbasis sinar-X, pemilahan berbasis optik, pemilahan berbasis pencitraan spektral, dan spektroskopi pembelahan yang diinduksi oleh laser (Gundupalli *et al.*, 2017). Namun, metode-metode ini memiliki beberapa keterbatasan. Misalnya, tenaga kerja manual mahal dan dapat menimbulkan potensi bahaya kesehatan (Lu *et al.*, 2022), sementara metode pemisahan logam, optik, dan mekanisme lainnya hanya dapat digunakan untuk mengidentifikasi material tertentu saja (Wu *et al.*, 2023).

Dengan peningkatan signifikan dalam *hardware* dan algoritma, teknologi *computer vision* telah mengalami perkembangan pesat. Teknologi ini menggunakan berbagai algoritma

*machine learning* maupun *deep learning* untuk melatih komputer dalam memperoleh dan menganalisis fitur-fitur bermakna dari input visual. *Computer vision* kini telah diterapkan dalam berbagai skenario pengenalan dan identifikasi yang mencakup hampir semua bidang kehidupan. Dalam sektor manufaktur, misalnya, teknologi ini digunakan untuk mengotomatisasi proses inspeksi kualitas dan pengawasan produksi (Villalba-Diez *et al.*, 2019). Di bidang kesehatan, *computer vision* digunakan untuk mendiagnosis penyakit dan menganalisis citra medis dengan akurasi yang tinggi (Esteva *et al.*, 2021). Selain itu, dalam sektor pertanian, teknologi ini membantu dalam pemantauan tanaman, pengelolaan hama, dan optimasi hasil panen (Bauer *et al.*, 2019). Implementasi *computer vision* di berbagai bidang ini menunjukkan potensinya yang besar untuk meningkatkan efisiensi, akurasi, dan produktivitas di berbagai industri.

Saat ini, sebagian besar masyarakat belum terbiasa dengan standar dan aturan spesifik dalam klasifikasi sampah, sehingga metode *computer vision* diperlukan untuk membantu masyarakat dalam mengklasifikasikan sampah. Dalam beberapa tahun terakhir, para peneliti telah melakukan riset intensif di bidang klasifikasi sampah dan telah mencapai kemajuan tertentu dalam pengenalan dan klasifikasi. Potensi penggunaan *computer vision* untuk segregasi sampah secara tidak langsung telah lama diakui. Gundupalli *et al.* (2016) memperkenalkan pendekatan untuk memilah sampah berdasarkan identifikasi otomatis dari citra termografi dan menggunakan algoritma *support vector machine* (SVM) untuk mendeteksi tiga jenis bahan daur ulang dari citra termografi. Tachwali *et al.* (2007) menggunakan algoritma *decision tree* untuk mengklasifikasikan botol plastik berdasarkan komposisi kimia dan warna, dan mencapai akurasi klasifikasi sebesar 83,48%.

Dalam beberapa tahun terakhir, *convolutional neural networks* (CNN) telah terbukti menjadi metode paling kuat dalam *computer vision* karena akurasinya yang sangat baik dan proses ekstraksi fitur yang otomatis. CNN memiliki kemampuan untuk mengidentifikasi dan mengklasifikasikan objek dalam gambar dengan tingkat presisi yang tinggi, membuatnya sangat efektif untuk berbagai aplikasi, salah satunya dalam pengklasifikasian sampah (Dhillon dan Verma, 2019). Karena sampah biasanya memiliki ciri visual yang signifikan, biaya tenaga kerja dan material dalam penerapan CNN jauh lebih rendah dibandingkan dengan potensi keuntungan dari pemulihan material. Oleh karena itu, CNN memiliki potensi aplikasi yang besar dalam tugas-tugas yang terkait dengan identifikasi dan daur ulang sampah dan layak untuk diteliti secara mendalam dan luas (Wu *et al.*, 2023).

Pada proyek ini, kami berfokus untuk meneliti lebih lanjut tentang pengklasifikasian sampah menggunakan salah satu jenis CNN, yaitu *You Only Look Once* (YOLO) (Redmon *et*

*al.*, 2016), lebih tepatnya YOLOv8 (Jocher *et al.*, 2023). Implementasi model YOLOv8 dalam pengklasifikasian sampah memiliki potensi besar untuk memisahkan sampah secara otomatis, yang pada gilirannya mempermudah proses daur ulang dan pengolahan lebih lanjut. Proyek ini difokuskan pada penggunaan robot KRTMI ASTRO\_24 dengan tujuan mengembangkan sistem yang dapat mengidentifikasi dan mengklasifikasikan jenis sampah secara real-time. Tujuannya adalah untuk mengurangi beban kerja manusia dan meningkatkan efisiensi pengelolaan sampah. Dengan demikian, implementasi teknologi ini diharapkan dapat memberikan kontribusi signifikan dalam mengurangi dampak negatif dari sampah domestik terhadap lingkungan dan memaksimalkan pemanfaatan sumber daya yang tersedia.

## **1.2 Rumusan Masalah**

Rumusan masalah dari topik yang akan dibahas adalah:

1. Bagaimana computer vision dapat membedakan berbagai jenis sampah?
2. Seberapa akurat computer vision dalam membedakan berbagai jenis sampah?

## **1.3 Tujuan**

Tujuan yang ingin dicapai oleh penulis dari topik ini adalah:

1. Meneliti dan memahami mekanisme kerja *computer vision* dalam proses identifikasi dan klasifikasi berbagai jenis sampah.
2. Mengukur tingkat akurasi *computer vision* dalam membedakan jenis-jenis sampah yang berbeda.

## **1.4 Manfaat**

Manfaat yang ingin dicapai oleh penulis adalah:

1. Memberikan wawasan mengenai penggunaan teknologi *computer vision* dalam pengelolaan sampah.
2. Membantu pengembangan sistem pengelolaan sampah yang lebih efisien dan otomatis dengan menggunakan *computer vision*.
3. Meningkatkan efektivitas proses daur ulang melalui identifikasi sampah yang lebih akurat dan cepat.

## 1.5 Batasan Masalah

Batasan masalah yang ditetapkan dalam topik ini adalah sebagai berikut:

1. Studi ini hanya akan fokus pada jenis sampah yang umum ditemukan dalam lingkungan rumah tangga dan industri ringan.
2. Penelitian ini menggunakan *dataset* yang tersedia secara publik atau yang dapat dikumpulkan dalam lingkungan terbatas.
3. Analisis hanya mencakup akurasi *computer vision* tanpa mempertimbangkan aspek biaya dan implementasi teknis dalam skala besar.
4. Evaluasi dilakukan menggunakan algoritma *computer vision* tertentu dan tidak mencakup perbandingan dengan semua algoritma yang ada.

## **BAB II**

### **TINJAUAN PUSTAKA**

#### **2.1 Sistem Pengklasifikasian Sampah Otomatis**

Peningkatan produksi sampah yang pesat dan pembuangan sampah yang tidak bertanggung jawab menjadi masalah yang sangat memprihatinkan. Pemilahan sampah otomatis memainkan peran penting dalam mencegah situasi ini dan memudahkan proses daur ulang (Reddy *et al.*, 2023). Memilah sampah sangat penting karena dapat meningkatkan jumlah sampah yang didaur ulang, sehingga mengurangi tekanan pada tempat pembuangan akhir. Dengan memilah sampah, kita dapat menurunkan pencemaran lingkungan yang diakibatkan oleh sampah yang tidak terkelola dengan baik. Selain itu, proses ini juga membantu dalam konservasi sumber daya alam dengan memaksimalkan pemanfaatan bahan yang dapat didaur ulang (Gundupalli *et al.*, 2017).

Pengelolaan sampah selalu menjadi aspek penting yang dievaluasi dalam masyarakat. Laju timbulan sampah meningkat pesat seiring dengan pertumbuhan jumlah penduduk, menambah urgensi untuk menemukan solusi yang efektif. Pengelolaan sampah yang efisien merupakan salah satu masalah lingkungan yang paling mendesak dan sangat penting untuk diatasi (Kamaruddin *et al.*, 2019). Salah satu cara untuk meningkatkan efisiensi pengelolaan sampah adalah dengan memisahkan sampah ke dalam aliran sederhana seperti sampah basah dan sampah kering. Proses daur ulang dan penggunaan kembali sampah menjadi lebih mudah ketika sampah dipisahkan sesuai jenisnya. Dengan pemisahan yang tepat, kita dapat memaksimalkan efisiensi daur ulang, mengurangi beban pada tempat pembuangan akhir, dan meminimalkan dampak negatif terhadap lingkungan. Langkah ini tidak hanya membantu dalam menjaga kelestarian lingkungan, tetapi juga mendorong masyarakat untuk lebih sadar akan pentingnya pengelolaan sampah yang bertanggung jawab. Melalui edukasi dan implementasi praktik pemilahan sampah yang baik, kita dapat mencapai lingkungan yang lebih bersih dan sehat untuk generasi mendatang (Fataniya *et al.*, 2019).

Salah satu fokus utama masyarakat kontemporer adalah pengelolaan sampah. Untuk mencapai daur ulang yang optimal, mengurangi limbah di tempat pembuangan akhir, dan meminimalkan dampak lingkungan, sangat penting untuk membagi sampah ke dalam kategori yang berbeda, seperti organik, dapat didaur ulang, dan tidak dapat didaur ulang. Dalam metode pemilahan sampah tradisional, pemilahan manual adalah cara yang paling umum; namun, cara ini sering memakan waktu, mahal, dan rentan terhadap kesalahan. Untuk meningkatkan dan

mengotomatiskan prosedur pemilahan sampah, teknik *machine learning* (ML) kini memanfaatkan *computer vision* dan kecerdasan buatan (AI). Dengan menggunakan teknologi ini, proses pemilahan sampah dapat dilakukan dengan lebih efisien dan akurat, mengurangi ketergantungan pada tenaga kerja manual dan mengoptimalkan hasil daur ulang. *Computer vision* memungkinkan sistem untuk mengenali dan mengklasifikasikan berbagai jenis sampah secara otomatis, sehingga mempercepat proses pengelolaan sampah dan meningkatkan efektivitas keseluruhan dalam upaya menjaga lingkungan (Borkar, P. & Channe, K. , 2023).

## 2.2 *Computer Vision*

*Computer vision*, atau yang sering disebut sebagai *machine vision*, adalah bidang studi yang berfokus pada mengajarkan mesin untuk "melihat". Ini merupakan area utama dalam aplikasi teknologi *deep learning*, yang banyak digunakan dalam pengemudian otomatis, pemeriksaan kualitas industri, dan aplikasi keamanan. Lebih spesifiknya, *computer vision* bertujuan untuk memungkinkan komputer mengenali objek dalam gambar atau video yang diambil oleh kamera, mendeteksi lokasi objek tersebut, dan melacaknya untuk memahami serta menafsirkan adegan dan narasi, mirip dengan cara sistem visual otak manusia bekerja. Tujuan utama dari *computer vision* adalah menciptakan sistem buatan yang dapat "merasakan" dan mengekstrak informasi dari gambar atau video, sehingga mampu menginterpretasikan dan menganalisis visual dengan tingkat akurasi yang tinggi (Che *et al.*, 2024).

Selain itu, *computer vision* adalah bagian dari kecerdasan buatan yang memungkinkan komputer melakukan berbagai fungsi, seperti melihat, merasakan, dan membuat keputusan. Deteksi objek adalah komponen penting dari *computer vision*. Ini bekerja dengan menentukan lokasi dan posisi objek serta label yang ada di dalam kotak pembatas (Mahendru dan Dubey, 2021). Pendeteksian objek banyak digunakan di berbagai bidang, salah satunya adalah dalam bidang pengelolaan sampah, di mana pengolahan gambar sampah membutuhkan identifikasi dan lokalisasi untuk mengklasifikasikan sampah tersebut (Borkar, P. & Channe, K., 2023). Ada peluang untuk meningkatkan ketepatan dan efektivitas pengklasifikasian sampah dengan bantuan *deep learning*.

Di bidang *computer vision*, *machine learning* telah mencapai kemajuan yang luar biasa. Salah satu algoritma *machine learning* yang populer adalah *artificial neural network* (ANN) yang telah banyak digunakan untuk penelitian tentang identifikasi dan klasifikasi sampah (Cai *et al.*, 2022). Misalnya, Yuan *et al.* (2021) mengusulkan jaringan residual ringan bernama



MAPMobileNet-18 untuk mengatasi masalah klasifikasi sampah, di mana mereka mengevaluasi kecepatan deteksi dan akurasi klasifikasi menggunakan perangkat tepi. Fu *et al.* (2021) mengembangkan metode klasifikasi sampah menggunakan model MobileNetV3 dan berhasil mencapai akurasi klasifikasi sebesar 92,62%; namun, struktur jaringan yang kompleks menyebabkan kecepatan komputasi yang sangat lambat. Untuk mengurangi jumlah parameter model dan meningkatkan akurasi deteksi, Chen *et al.* (2021) menggunakan tulang punggung MobileNet-2 untuk distilasi model deteksi sampah; meskipun demikian, mereka tidak mempertimbangkan kemampuan generalisasi model tersebut.

Namun, dibandingkan dengan metode-metode tersebut, Convolutional Neural Networks (CNN) terutama YOLOv8 (You Only Look Once) memiliki beberapa keunggulan. YOLOv8 terkenal dengan kemampuannya untuk melakukan deteksi objek secara real-time dengan akurasi tinggi dan kecepatan komputasi yang cepat. Keunggulan ini sangat penting dalam aplikasi pengklasifikasian sampah, di mana deteksi dan klasifikasi yang cepat dan akurat diperlukan untuk mengoptimalkan proses daur ulang. Selain itu, YOLOv8 memiliki struktur jaringan yang efisien yang memungkinkan pemrosesan gambar secara cepat tanpa mengorbankan akurasi, serta mampu menangani variasi dan kompleksitas objek dalam gambar dengan lebih baik. Dengan kemampuan untuk menggabungkan deteksi dan klasifikasi dalam satu langkah, YOLOv8 dapat memberikan hasil yang lebih konsisten dan andal dalam berbagai kondisi operasional.

Dengan berbagai pendekatan ini, teknologi visi komputer terus menunjukkan potensinya dalam meningkatkan efisiensi dan akurasi klasifikasi sampah, yang pada akhirnya dapat membantu dalam pengelolaan sampah yang lebih baik dan ramah lingkungan. Implementasi model YOLOv8 dapat menjadi solusi yang lebih unggul dalam pemilahan sampah secara otomatis, mengatasi keterbatasan metode sebelumnya, dan memberikan kontribusi signifikan terhadap pengelolaan sampah yang berkelanjutan.

## **2.3 Convolutional Neural Networks (CNN)**

*Convolutional Neural Networks (CNN)* merupakan salah satu metode paling berhasil dalam pengenalan pola. Mereka menggunakan filter yang dilatih secara lokal untuk mengekstrak fitur visual dari gambar masukan, diikuti oleh operasi penggabungan untuk mengurangi ukuran peta fitur. *Computer vision* berbasis CNN telah memungkinkan pencapaian yang sebelumnya dianggap tidak mungkin dalam beberapa abad terakhir, seperti *face*

*recognitions, autonomous vehicles, self-service supermarkets, and intelligent medical treatments.* Ada Tiga komponen utama dalam *Convolutional Neural Networks (CNN)*, yaitu konvolusi, pooling, dan lapisan terhubung penuh (*fully connected layer*), serta teknik-teknik penting yang digunakan dalam pelatihan CNN untuk mengatasi masalah seperti *overfitting* (Sarigül, M et al 2019).

Konvolusi merupakan operasi inti dalam CNN dimana filter dengan ukuran tetap yaitu 3x3 pixel digunakan untuk mengekstrak fitur visual dari gambar masukan. Proses ini dilakukan dengan menggeser filter yang dilatih secara lokal di atas gambar, dan setiap filter memiliki bobot dan bias yang sama di seluruh gambar. Konvolusi memungkinkan representasi fitur yang sama dipetakan ke seluruh gambar, dan dapat menggunakan fungsi aktivasi seperti *ReLU* atau *sigmoid*. *Pooling* adalah proses yang diterapkan pada peta fitur yang telah melewati konvolusi dan fungsi aktivasi. Hal ini menghasilkan peta fitur yang lebih kecil yang merupakan ringkasan dari peta fitur masukan. Operasi *pooling* dapat berupa pooling maksimum, rata-rata, atau L2, yang membantu dalam mereduksi ukuran gambar dan mengekstraksi fitur visual secara independen.

Setelah lapisan konvolusi dan *pooling*, data diubah menjadi vektor satu dimensi yang menjadi masukan dari jaringan terhubung penuh. Struktur ini dapat memiliki satu atau lebih lapisan tersembunyi, di mana setiap neuron mengalikan bobot koneksi dengan data dari lapisan sebelumnya, menambahkan nilai bias, dan melewati fungsi aktivasi sebelum ditransmisikan ke lapisan berikutnya.

Implementasi CNN pada multidimensional data, seperti pada kasus 3D CNN, memiliki beberapa aplikasi yang biasa diterapkan, seperti Pengenalan Gerakan Manusia (Human Action Recognition) dalam aplikasi ini, CNN digunakan untuk mengenali gerakan manusia dalam video. Pendekatan ini dapat mencakup penggunaan 3D CNN untuk mengekstrak fitur dari sendi-sendi tubuh manusia atau menggunakan konvolusi 3D pada video untuk mengekstrak pola spasial-temporal. Pengenalan dan Deteksi Objek (Object Recognition/Detection), CNN digunakan untuk mendeteksi dan mengenali objek dalam gambar atau video 3D. Penggunaan 3D CNN seperti VoxNet atau penggunaan arsitektur gabungan yang menggabungkan output dari arsitektur 2D CNN dan 3D CNN dapat membantu dalam tugas-tugas ini. Penggunaan pada Gambaran Tinggi (High-dimensional Images) CNN juga dapat digunakan untuk mendeteksi objek dalam gambaran yang memiliki dimensi tinggi, seperti sinar-X atau gambar CT. Penggunaan 3D CNN dalam kasus ini memungkinkan analisis yang lebih menyeluruh dari gambaran yang kompleks.

Implementasi CNN pada multidimensional data menghadirkan tantangan unik karena kompleksitas data yang lebih tinggi dan membutuhkan desain arsitektur jaringan yang tepat untuk mengekstrak fitur-fitur yang relevan dengan efisien. Selain itu, ada juga penelitian yang berkembang untuk mencari cara-cara baru untuk meningkatkan efisiensi, akurasi, dan skalabilitas jaringan CNN dalam konteks multidimensional (Li, Z *et al.*, 2022).

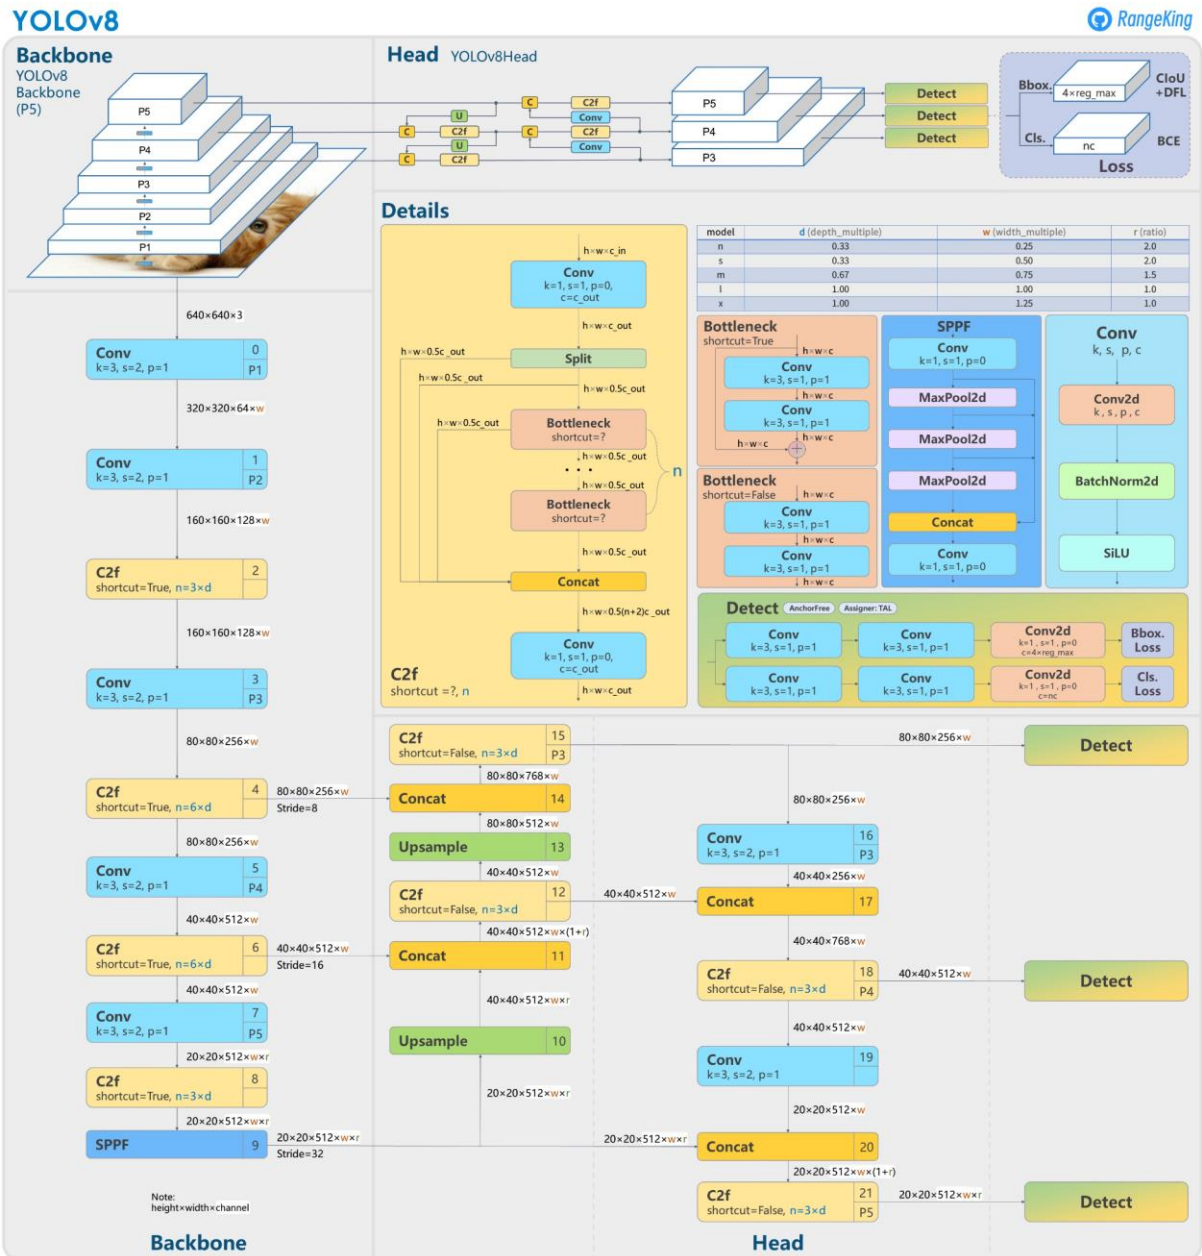
## 2.4 YOLOv8

YOLOv8 (*You Only Look Once* version 8) merupakan model penerapan Convolutional Neural Networks (CNN). YOLO pertama kali diperkenalkan oleh Joseph Redmon dan tim nya pada tahun 2015 (Zou *et al.*, 2023). Sejak saat itu, YOLO mengalami iterasi yang signifikan. Hingga saat ini, YOLOv8 sudah meningkat secara akurasi dan efisiensi pendeteksian objek.

Perkembangan YOLO selalu berfokus pada kecepatan dan akurasi. Dalam kebanyakan kasus, versi terbaru memasukkan pembaruan arsitektur jaringan, optimasi algoritma, dan teknik pelatihan yang signifikan. Misalnya, YOLOv8 meningkatkan kinerja di berbagai kondisi pencahayaan dan lingkungan melalui penggunaan model *pre-processing* yang lebih efisien dan metode pemrosesan data yang lebih canggih (Hsu & Lin *et al.*, 2021). Dengan peningkatan ini, YOLOv8 dapat mengenali objek dengan lebih baik dan lebih cepat daripada versi sebelumnya.

Secara teknis, YOLOv8 menggunakan metode *single stage detection*, yang memungkinkan model untuk memproses gambar dan mendeteksi objek dalam satu langkah (M. Safaldin *et al.*, 2024). Tidak seperti *double stage detection* yang memisahkan proses pencarian region proposal dan klasifikasi objek. Kemampuannya untuk melakukan deteksi real-time dengan kecepatan yang sangat tinggi tanpa mengurangi akurasi adalah keunggulan utama YOLOv8. Ini membuatnya ideal untuk aplikasi yang membutuhkan respons cepat, seperti sistem pengawasan, kendaraan otonom, dan aplikasi AR.

YOLOv8 berhasil memanfaatkan teknologi terbaru seperti pengoptimalan tensor dan penggunaan GPU untuk mempercepat proses inferensi berkat kemajuan teknologi dan peningkatan kemampuan komputasi (L. Shen *et al.*, 2023). Selain itu, model ini dirancang untuk lebih mudah diintegrasikan dengan berbagai framework *machine learning*, sehingga dapat digunakan di berbagai industri. Selain itu, YOLOv8 adalah solusi yang sangat baik untuk mendeteksi objek dalam situasi dunia nyata yang kompleks karena mampu beroperasi dengan baik dalam berbagai kondisi lingkungan.



Gambar 2.1 Arsitektur YOLOv8 (RangeKing *et al.*, 2023)

Secara keseluruhan, YOLOv8 adalah kemajuan besar dalam teknologi *object detection* yang terus menciptakan standar baru dalam hal kecepatan dan akurasi. Dengan arsitekturnya yang lebih efisien dan integrasi teknologi terbaru, YOLOv8 meningkatkan kinerja deteksi dan meluas aplikasinya ke berbagai bidang, seperti keamanan dan otomasi industri.

## **BAB III**

### **PEMBAHASAN DAN ANALISA DATA**


#### **3.1 Pengambilan Data**

Untuk pembuatan model, kami mengumpulkan dan menggunakan 10,320 data gambar sampah yang terbagi menjadi 9 kategori. Setiap kategori sampah dipilih berdasarkan relevansi dan prevalensi dalam lingkungan sehari-hari, memastikan bahwa model yang dikembangkan dapat mengidentifikasi dan mengklasifikasikan jenis sampah yang umum ditemui. Kategori-kategori tersebut adalah sebagai berikut: botol, daun basah, daun kering, logam ferro, kertas bungkus, logam non-ferro, koran, plastik biru, dan plastik putih.


Proses pengambilan data dilakukan melalui beberapa tahap yang teliti. Pertama, kami mengumpulkan sampah dari berbagai sumber seperti rumah tangga, perkantoran, dan tempat umum. Selanjutnya, setiap jenis sampah dipisahkan dan dikelompokkan sesuai dengan kategorinya. Setelah itu, kami memotret setiap sampah dengan menggunakan kamera resolusi tinggi untuk memastikan kualitas gambar yang baik. Pengambilan gambar dilakukan dalam kondisi pencahayaan yang seragam untuk mengurangi variabilitas dan memastikan konsistensi data.

Setiap gambar diambil dari berbagai sudut dan posisi untuk menangkap variasi yang mungkin terjadi dalam pengenalan objek. Hal ini dilakukan untuk memastikan bahwa model dapat mengenali sampah dalam berbagai kondisi nyata. Gambar-gambar tersebut kemudian diberi label secara manual sesuai dengan kategorinya untuk menyediakan data pelatihan yang akurat bagi model.

Data yang terkumpul kemudian disimpan dalam format yang terorganisir dan dipecah menjadi set pelatihan, validasi, dan pengujian. Set pelatihan digunakan untuk melatih model, sementara set validasi dan pengujian digunakan untuk mengevaluasi kinerja model. Pembagian data ini dilakukan untuk memastikan bahwa model yang dikembangkan tidak hanya efektif dalam mengenali gambar yang telah dilatih, tetapi juga memiliki kemampuan generalisasi yang baik untuk mengenali gambar baru yang belum pernah dilihat sebelumnya.



(a)




(b)




(c)




(d)




(e)




(f)



(g)



(h)



(i)

Gambar 3.1 Contoh data gambar sampah yang telah diberi label (a) Botol plastik, (b) Daun basah, (c) Daun kering, (d) Logam *ferro*, (e) Kertas bungkus, (f) Kertas koran, (g) Logam *non-ferro*, (h) Plastik biru, (i) Plastik putih



### 3.2 Pra-Pemrosesan Data

Pada tahap pra-pemrosesan dalam penelitian ini, beberapa langkah penting dilakukan untuk mempersiapkan *dataset* dan gambar guna melatih model YOLOv8. Langkah pertama adalah penerapan proses “*Auto-Orient*” pada gambar. Proses ini memastikan orientasi gambar yang benar, mencegah rotasi yang tidak diinginkan yang dapat mempengaruhi kemampuan model dalam belajar dan membuat prediksi yang akurat (Rayan *et al.*, 2021).

Langkah berikutnya adalah operasi “*Resize*” atau perubahan ukuran, di mana setiap gambar diubah ukurannya menjadi resolusi tetap 640×640 piksel. Perubahan ukuran ini sangat penting untuk memastikan bahwa semua gambar memiliki dimensi yang seragam, sebuah prasyarat yang krusial bagi model YOLOv8 untuk memproses mereka secara efisien. Dengan gambar yang memiliki ukuran konsisten, model dapat mengoptimalkan pemrosesan data dan meningkatkan akurasi dalam mengidentifikasi serta mengklasifikasikan berbagai jenis sampah.

Selain itu, langkah-langkah tambahan dalam pra-pemrosesan mungkin termasuk normalisasi warna dan kontras untuk meningkatkan kualitas gambar, serta augmentasi data untuk menambah variasi dalam *dataset*. Augmentasi data dapat mencakup teknik seperti rotasi, pemotongan, pencerminan, dan perubahan intensitas warna. Teknik-teknik ini membantu model untuk lebih robust dalam menghadapi variasi kondisi nyata di lapangan.

Dengan menerapkan langkah-langkah pra-pemrosesan yang komprehensif ini, *dataset* yang digunakan untuk melatih model YOLOv8 menjadi lebih siap dan terstruktur, memungkinkan model untuk mencapai performa yang lebih tinggi dalam tugas pengenalan dan klasifikasi sampah. Hasil dari tahap pra-pemrosesan ini adalah *dataset* yang konsisten, berkualitas tinggi, dan representatif, yang secara signifikan meningkatkan kemampuan model dalam memprediksi dan mengklasifikasikan gambar sampah dengan akurasi yang lebih baik.

### 3.3 Pembuatan Model YOLOv8

Langkah pertama dalam pembuatan model YOLOv8 adalah menyiapkan *dataset* gambar. Pada kasus ini, *custom dataset* kami unggah melalui *platform* Roboflow, di mana kita dapat mengekstrak file *dataset* atau memanggilnya dengan memasukkan API KEY yang diberikan. Setelah *dataset* gambar disiapkan, proses pelatihan model deteksi objek dan *instance segmentation* menggunakan arsitektur YOLOv8 dapat dimulai.

Proses pelatihan melibatkan beberapa langkah penting, seperti memilih *hyperparameter* yang sesuai, menentukan *dataset* pelatihan dan validasi, serta menjalankan pelatihan pada model. *Hyperparameter* yang perlu disesuaikan meliputi ukuran jendela geser, jumlah lapisan konvolusi, dan jumlah neuron di lapisan terakhir. Pemilihan *hyperparameter* yang tepat sangat penting untuk memastikan model dapat belajar dengan efektif dan menghasilkan prediksi yang akurat (Putra & Mulyana, 2024).

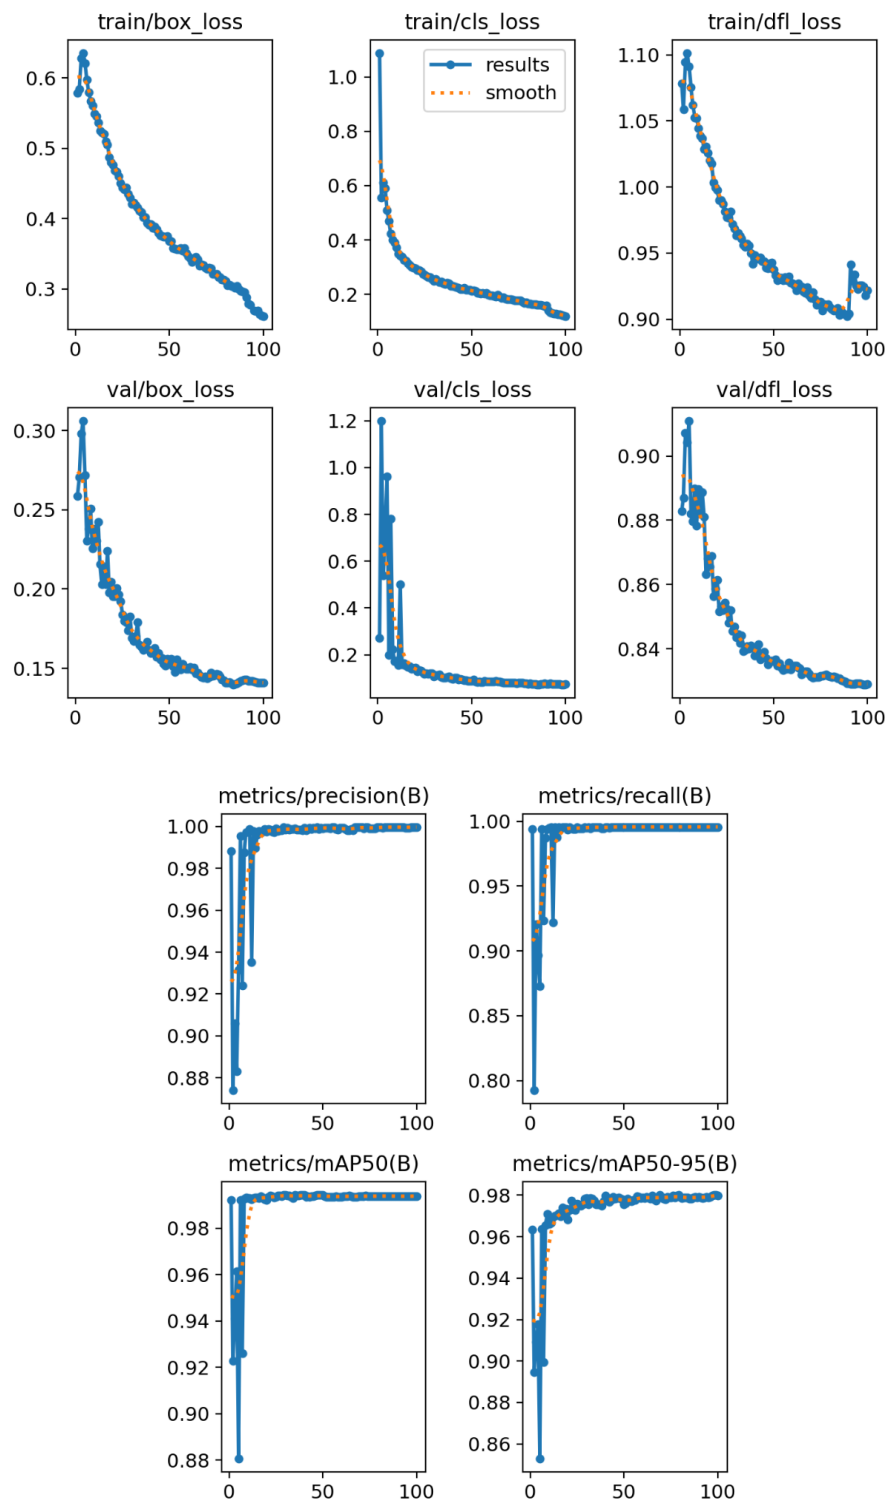
Setelah pembuatan *dataset* di Roboflow, tahap berikutnya adalah pelatihan *dataset*. Pelatihan dilakukan menggunakan platform *Google Colaboratory*, yang menyediakan sumber daya komputasi yang diperlukan untuk proses ini. Pelatihan model melibatkan penggunaan citra yang telah dilabeli, di mana model berusaha menemukan dan mempelajari nilai-nilai yang optimal (*good values*) untuk setiap bobot dan bias, sehingga dapat meminimalkan kesalahan prediksi. Proses ini dikenal sebagai *training*.

Pada tahap ini, peneliti menggunakan *library* Python bernama *Ultralytics* untuk mengimpor algoritma YOLOv8. *Library* ini menyediakan berbagai alat dan fungsi yang memudahkan proses pelatihan model. Dengan menggunakan YOLOv8 dari *library Ultralytics*, model dilatih untuk mendeteksi dan mengklasifikasikan objek dalam gambar dengan tingkat akurasi yang tinggi. *Google Colaboratory* digunakan untuk menjalankan skrip pelatihan, karena platform ini menawarkan GPU yang kuat yang mempercepat proses pelatihan model.

Penting untuk melakukan validasi selama proses pelatihan. *Dataset* validasi digunakan untuk menguji model pada data yang tidak dilihat selama pelatihan, guna memastikan model tidak mengalami *overfitting* dan memiliki kemampuan generalisasi yang baik. Proses validasi ini membantu dalam menyesuaikan *hyperparameter* dan meningkatkan performa model secara keseluruhan. Selain itu, pembuatan model dilakukan dengan input *size* 640 x 640, 100 *epochs*, dan *batch size* 8. Pengaturan ini membantu memastikan bahwa semua gambar memiliki dimensi yang sama dan model dilatih dengan cukup iterasi untuk mencapai kinerja yang optimal.

Dengan langkah-langkah ini, model YOLOv8 dapat dibangun dan dilatih dengan baik, siap untuk digunakan dalam tugas deteksi objek dan segmentasi instance pada berbagai aplikasi, termasuk pengklasifikasian sampah yang efisien dan akurat. Proses yang komprehensif dan terstruktur ini memastikan bahwa model yang dihasilkan memiliki kinerja yang optimal dalam lingkungan nyata.

### 3.4 Evaluasi Model



Gambar 3.2 Hasil evaluasi data *training*

Keakuratan algoritma YOLOv8 untuk deteksi objek bergantung pada berbagai parameter evaluasi, termasuk *train/box\_loss*, *train/cls\_loss*, *train/dfl\_loss*, *val/box\_loss*,

*val/cls\_loss*, *val/dfl\_loss*, *metrics/precision(B)*, *metrics/recall(B)*, *metrics/mAP50(B)*, dan *metrics/mAP50-95(B)*. Metrik *train/box\_loss* mengukur kesalahan prediksi posisi *bounding box* selama proses pelatihan, dengan nilai lebih rendah menunjukkan akurasi yang lebih tinggi dalam menentukan lokasi objek. *Train/cls\_loss* mengukur kesalahan klasifikasi selama pelatihan, di mana nilai yang lebih rendah menunjukkan kemampuan yang lebih baik dalam mengklasifikasikan objek dengan benar. *Train/dfl\_loss*, atau *Dual Focal Loss*, digunakan untuk menangani ketidakseimbangan kelas dalam *dataset*, memberikan bobot lebih pada sampel yang salah klasifikasi untuk meningkatkan akurasi prediksi kelas yang kurang terwakili (Panteleimon, 2023).

Pada proses validasi, *val/box\_loss* dan *val/cls\_loss* mengukur kesalahan prediksi *bounding box* dan kesalahan klasifikasi pada data validasi, memastikan model tidak mengalami *overfitting* dan mampu bekerja dengan baik pada data baru. *Val/dfl\_loss* menilai efektivitas model dalam menangani ketidakseimbangan kelas pada data validasi (Panteleimon, 2023). *Metrics/precision(B)* dan *metrics/recall(B)* adalah indikator penting dari ketepatan dan kemampuan deteksi model, dengan nilai yang lebih tinggi menunjukkan hasil yang lebih akurat dan sedikit objek yang terlewatkan. *Metrics/mAP50(B)* mengukur mean average precision pada ambang batas IoU 0,50, sementara *metrics/mAP50-95(B)* memberikan penilaian yang lebih komprehensif terhadap kinerja pendeteksian pada berbagai tingkat ambang batas IoU, dari 0,50 hingga 0,95 (Soylu & Soyly, 2023).

Tren yang diamati selama peningkatan jumlah *epoch* pada model YOLOv8 menunjukkan hasil yang semakin baik. Penurunan *train/box\_loss* dan *val/box\_loss* menunjukkan peningkatan akurasi dalam memprediksi lokasi objek. Penurunan *train/cls\_loss* dan *val/cls\_loss* menandakan peningkatan akurasi klasifikasi, sementara penurunan *train/dfl\_loss* dan *val/dfl\_loss* menunjukkan kemampuan yang lebih baik dalam menangani ketidakseimbangan kelas. Peningkatan *metrics/precision(B)* dan *metrics/recall(B)* menunjukkan bahwa model semakin mampu mendeteksi objek dengan tepat dan tidak banyak objek yang terlewatkan. Selain itu, peningkatan *metrics/mAP50(B)* dan *metrics/mAP50-95(B)* menunjukkan bahwa model semakin baik dalam mendeteksi objek pada berbagai tingkat kesulitan, dengan presisi yang tinggi di seluruh spektrum IoU. Secara keseluruhan, tren positif ini menunjukkan bahwa model YOLOv8 yang dilatih dengan input *size* 640 x 640, 100 *epochs*, dan *batch size* 8, berhasil meningkatkan kinerjanya seiring dengan bertambahnya jumlah *epoch*, menjadikannya sangat efektif untuk aplikasi seperti pengklasifikasian sampah yang efisien dan akurat.

## **BAB IV**

### **KESIMPULAN DAN SARAN**

#### **4.1 Kesimpulan**

Pada proyek ini, penulis bertujuan untuk meneliti dan memahami mekanisme kerja *computer vision* dalam proses identifikasi dan klasifikasi berbagai jenis sampah, serta mengukur tingkat akurasi teknologi tersebut dalam membedakan jenis-jenis sampah yang berbeda. Berdasarkan hasil yang diperoleh dari pelatihan model menggunakan 100 *epoch*, didapatkan hasil yang sangat memuaskan.

Model YOLOv8 yang dikembangkan menunjukkan kinerja yang sangat tinggi dengan mean average precision (mAP) sebesar 99,4%. Angka ini menunjukkan bahwa sistem memiliki tingkat keakuratan yang sangat tinggi dalam mendeteksi dan mengklasifikasikan berbagai jenis sampah. Selain itu, precision mencapai angka sempurna 100%, yang mengindikasikan bahwa semua sampah yang terdeteksi oleh sistem adalah benar-benar sampah dari jenis yang tepat, tanpa ada kesalahan deteksi. Recall yang diperoleh sebesar 99,6% menunjukkan bahwa hampir semua jenis sampah yang ada dalam dataset berhasil dideteksi oleh sistem, dengan hanya sedikit yang terlewatkan.

Kesimpulannya, melalui penelitian ini, penulis berhasil menunjukkan bahwa *computer vision*, khususnya dengan menggunakan model YOLOv8, dapat mencapai tingkat akurasi yang sangat tinggi dalam proses identifikasi dan klasifikasi berbagai jenis sampah. Hasil ini menegaskan potensi besar dari teknologi ini untuk diterapkan dalam sistem pengelolaan sampah yang lebih efisien dan efektif, mendukung upaya pelestarian lingkungan dengan lebih baik.

#### **4.2 Saran**

Pengklasifikasian sampah menggunakan YOLOv8 pada uji coba di atas memang sudah cukup akurat untuk membedakan sampah dengan benar, tetapi dalam beberapa kasus, pembacaan sampah tidak dapat terdeteksi secara baik. Salah satu faktor yang mempengaruhi hasil ini adalah variasi dalam kondisi pencahayaan saat pengambilan gambar. Meskipun pencahayaan telah diusahakan konsisten, perubahan kecil atau fluktuasi alami dalam intensitas cahaya dapat mempengaruhi kemampuan model untuk mendeteksi objek dengan akurasi tinggi.

Selain itu, model YOLOv8 memiliki keterbatasan dalam mendeteksi objek yang memiliki kemiripan pada bentuk, warna, maupun tekstur. Misalnya, sampah plastik berwarna biru dan putih mungkin sulit dibedakan jika keduanya memiliki bentuk dan tekstur yang mirip. Untuk mengatasi masalah ini, sebaiknya dilakukan iterasi yang banyak dan memasukkan dataset yang beragam serta representatif. Dengan menambahkan variasi data yang lebih luas dan mencakup berbagai kondisi nyata, model dapat belajar lebih baik dan meningkatkan kemampuannya dalam membedakan objek yang serupa. Ini juga membantu dalam menghindari kekurangan data dan mengurangi risiko *overfitting*, sehingga model dapat bekerja lebih baik dalam situasi yang lebih umum.

Secara keseluruhan, untuk meningkatkan akurasi dan efektivitas model YOLOv8 dalam pengklasifikasian sampah, perlu diperhatikan beberapa aspek penting seperti diversifikasi dataset dan iterasi pelatihan yang ekstensif. Dengan melakukan perbaikan dan penyesuaian ini, diharapkan model dapat memberikan hasil yang lebih andal dan akurat dalam berbagai kondisi nyata.

## DAFTAR PUSTAKA

- Bauer, A., Bostrom, A. G., Ball, J., Applegate, C., Cheng, T., Laycock, S., ... Zhou, J. (2019). Combining computer vision and deep learning to enable ultra-scale aerial phenotyping and precision agriculture: A case study of lettuce production. *Horticulture Research*, 6(1). <https://doi.org/10.1038/s41438-019-0151-5>
- Borkar, P., & Channe, K. (2023). Detection and Classification of Waste for Segregation Based on Machine Learning. *Lecture Notes in Networks and Systems*, 588, 119–132. [https://doi.org/10.1007/978-981-19-7982-8\\_11](https://doi.org/10.1007/978-981-19-7982-8_11)
- Cai, X., Shuang, F., Sun, X., Duan, Y., & Cheng, G. (2022). Towards Lightweight Neural Networks for Garbage Object Detection. *Sensors*, 22(19), 7455. <https://doi.org/10.3390/s22197455>
- Che, C., Zheng, H., Huang, Z., Jiang, W., & Liu, B. (2024). Intelligent Robotic Control System Based on Computer Vision Technology. <https://doi.org/10.48550/arXiv.2404.01116>
- Chen, Z., Jiao, H., Yang, J., & Zeng, H. (2021). Garbage image classification algorithm based on improved MobileNet v2. *Journal of ZheJiang University (Engineering Science)*, 55(8), 1490–1499. <https://doi.org/10.3785/j.issn.1008-973x.2021.08.010>
- Dhillon, A., & Verma, G. K. (2019). Convolutional neural network: a review of models, methodologies and applications to object detection. *Progress in Artificial Intelligence*, 9(2), 85–112. <https://doi.org/10.1007/s13748-019-00203-0>
- Esteva, A., Chou, K., Yeung, S., Naik, N., Madani, A., Mottaghi, A., ... Socher, R. (2021). Deep learning-enabled medical computer vision. *Npj Digital Medicine*, 4(1). <https://doi.org/10.1038/s41746-020-00376-2>
- Fataniya, B., Sood, A., Poddar, D., & Shah, D. (2019). Implementation of IoT Based Waste Segregation and Collection System. *ProQuest*, 65(4), 579–584. <https://doi.org/10.24425/ijet.2019.129816>

- Fu, B.-W., Li, S., Wei, J., Li, Q., Wang, Q., & Tu, J. (2021). A Novel Intelligent Garbage Classification System Based on Deep Learning and an Embedded Linux System. *IEEE*, 9, 131134–131146. <https://doi.org/10.1109/access.2021.3114496>
- Goulart Coelho, L. M., & Lange, L. C. (2018). Applying life cycle assessment to support environmentally sustainable waste management strategies in Brazil. *Resources, Conservation and Recycling*, 128, 438–450. <https://doi.org/10.1016/j.resconrec.2016.09.026>
- Gundupalli, S. P., Hait, S., & Thakur, A. (2017). A review on automated sorting of source-separated municipal solid waste for recycling. *Waste Management*, 60, 56–74. <https://doi.org/10.1016/j.wasman.2016.09.015>
- Jocher, G., Chaurasia, A., & Jing, Q. (2023). Ultralytics YOLO. Retrieved June 6, 2024, from GitHub website: <https://github.com/ultralytics/ultralytics>
- Kamaruddin, N. H., Rahim, A. A. A., Abdullah, N. E., Halim, I. S. A., & Hassan, S. L. M. (2019). Development of Automatic Waste Segregator with Monitoring System. *2019 4th International Conference on Information Technology, Information Systems and Electrical Engineering (ICITISEE)*, 190–195. Yogyakarta, Indonesia,. Retrieved from 10.1109/ICITISEE48480.2019.9003813
- Kaza, S., Yao, L., Bhada-Tata, P., & Van Woerden, F. (2018). What a Waste 2.0: A Global Snapshot of Solid Waste Management to 2050. *What a Waste 2.0 : A Global Snapshot of Solid Waste Management to 2050*. <https://doi.org/10.1596/978-1-4648-1329-0>
- Lu, Y., Yang, B., Gao, Y., & Xu, Z. (2022). An automatic sorting system for electronic components detached from waste printed circuit boards. *Waste Management*, 137, 1–8. <https://doi.org/10.1016/j.wasman.2021.10.016>
- Mahendru, M., & Dubey, S. (2021). Real time object detection with audio feedback using Yolo vs. Yolo\_V3. *Proceedings of the Confluence 2021: 11th International Conference on*



- Cloud Computing, Data Science and Engineering*, 734–740. Retrieved from 10.1109/Confluence51648.2021.9377064.
- Panteleimon, N. (2023). *Propulsion Shafting Arrangement Modeling from Mechanical Drawings using Deep Learning and YOLOv8*. National Technical University Of Athens.
- Putra, R. F., & Mulyana, D. I. (2024). Optimasi Deteksi Objek Dengan Segmentasi dan Data Augmentasi Pada Hewan Siput Beracun Menggunakan Algoritma You Only Look Once (YOLO). *Jurnal JTIK (Jurnal Teknologi Informasi Dan Komunikasi)*, 8(1), 93–103. <https://doi.org/10.35870/jtik.v8i1.1391>
- RangeKing et al. (2023). Brief summary of YOLOv8 model structure · Issue #189 · ultralytics/ultralytics. Retrieved from GitHub website: <https://github.com/ultralytics/ultralytics/issues/189>
- Rayan, M. A., Rahim, A., Rahman, A., Marjan, Md. A., & Ali, U. A. M. E. (2021). Fish Freshness Classification Using Combined Deep Learning Model. *2021 International Conference on Automation, Control and Mechatronics for Industry 4.0 (ACMI)*. <https://doi.org/10.1109/acmi53878.2021.9528138>
- Reddy, P. L., Sabiha, S. K., Sabiha, P., Dinesh, & Naveen, V. (2023). Optimized garbage segregation and monitoring system. *Materials Today: Proceedings*, 80(3), 3376–3379. <https://doi.org/10.1016/j.matpr.2021.07.256>
- Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. *Dalam Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779–788.
- Sathish Gundupalli Paulraj, Hait, S., & Ajay Singh Thakur. (2016). Automated Municipal Solid Waste Sorting for Recycling Using a Mobile Manipulator. *Dalam ASME 2016*

*International Design Engineering Technical Conferences and Computers and Information in Engineering Conference*. <https://doi.org/10.1115/detc2016-59842>

Soylu, E., & Soyly, T. (2023). A performance comparison of YOLOv8 models for traffic sign detection in the Robotaxi-full scale autonomous vehicle competition. *Multimedia Tools and Applications*, 83. <https://doi.org/10.1007/s11042-023-16451-1>

Tachwali, Y., Al-Assaf, Y., & Al-Ali, A. R. (2007). Automatic multistage classification system for plastic bottles recycling. *Resources, Conservation and Recycling*, 52(2), 266–285. <https://doi.org/10.1016/j.resconrec.2007.03.008>

Villalba-Diez, J., Schmidt, D., Gevers, R., Ordieres-Meré, J., Buchwitz, M., & Wellbrock, W. (2019). Deep Learning for Industrial Computer Vision Quality Control in the Printing Industry 4.0. *Sensors*, 19(18), 3987. <https://doi.org/10.3390/s19183987>

Wu, T.-W., Zhang, H., Peng, W., Lü, F., & He, P.-J. (2023). Applications of convolutional neural networks for intelligent waste identification and recycling: A review. *Resources, Conservation and Recycling*, 190, 106813. <https://doi.org/10.1016/j.resconrec.2022.106813>

Yuan, J., Nan, X., Cai, X., & Li, C. (2021). Garbage Image Classification By Lightweight Residual Network. *Environmental Engineering*, 39(2), 110–115. <https://doi.org/10.13205/j.hjgc.202102017>

Zhang, Q., Yang, Q., Zhang, X., Wei, W., Bao, Q., Su, J., & Liu, X. (2022). A multi-label waste detection model based on transfer learning. *Resources, Conservation and Recycling*, 181, 106235. <https://doi.org/10.1016/j.resconrec.2022.106235>

Zou, Z., Chen, K., Shi, Z., Guo, Y., & Ye, J. (2023). Object detection in 20 years: A survey. *Proceedings of the IEEE*, 111(3), 257-276. <https://doi.org/10.1109/jproc.2023.3238524>

- Hsu, W. Y., & Lin, W. Y. (2020). Ratio-and-scale-aware YOLO for pedestrian detection. *IEEE transactions on image processing*, 30, 934-947. <https://doi.org/10.1109/tip.2020.3039574>
- Safaldin, M., Zaghdien, N., & Mejdoub, M. (2024). An Improved YOLOv8 to Detect Moving Objects. *IEEE Access*. <https://doi.org/10.1109/access.2024.3393835>
- Shen, L., Lang, B., & Song, Z. (2023). Infrared Object Detection Method Based on DBD-YOLOv8. *IEEE Access*. <https://doi.org/10.1109/access.2023.3345889>
- Li, Z., Liu, F., Yang, W., Peng, S., & Zhou, J. (2021). A survey of convolutional neural networks: analysis, applications, and prospects. *IEEE transactions on neural networks and learning systems*, 33(12), 6999-7019. <https://doi.org/10.1109/tnnls.2021.3084827>
- Kiranyaz, S., Avci, O., Abdeljaber, O., Ince, T., Gabbouj, M., & Inman, D. J. (2021). 1D convolutional neural networks and applications: A survey. *Mechanical systems and signal processing*, 151, 107398. <https://doi.org/10.1016/j.ymssp.2020.107398>
- Sarıgül, M., Ozyildirim, B. M., & Avci, M. (2019). Differential convolutional neural network. *Neural Networks*, 116, 279-287. <https://doi.org/10.1016/j.neunet.2019.04.025>
- Zhang, Q., Zhang, M., Chen, T., Sun, Z., Ma, Y., & Yu, B. (2019). Recent advances in convolutional neural network acceleration. *Neurocomputing*, 323, 37-51. <https://doi.org/10.1016/j.neucom.2018.09.038>
- Wong, A., Famuori, M., Shafiee, M. J., Li, F., Chwyl, B., & Chung, J. (2019, December). YOLO nano: A highly compact you only look once convolutional neural network for object detection. In *2019 Fifth Workshop on Energy Efficient Machine Learning and Cognitive Computing-NeurIPS Edition (EMC2-NIPS)* (pp. 22-25). IEEE. <https://doi.org/10.1109/emc2-nips53020.2019.00013>

## **LAMPIRAN**